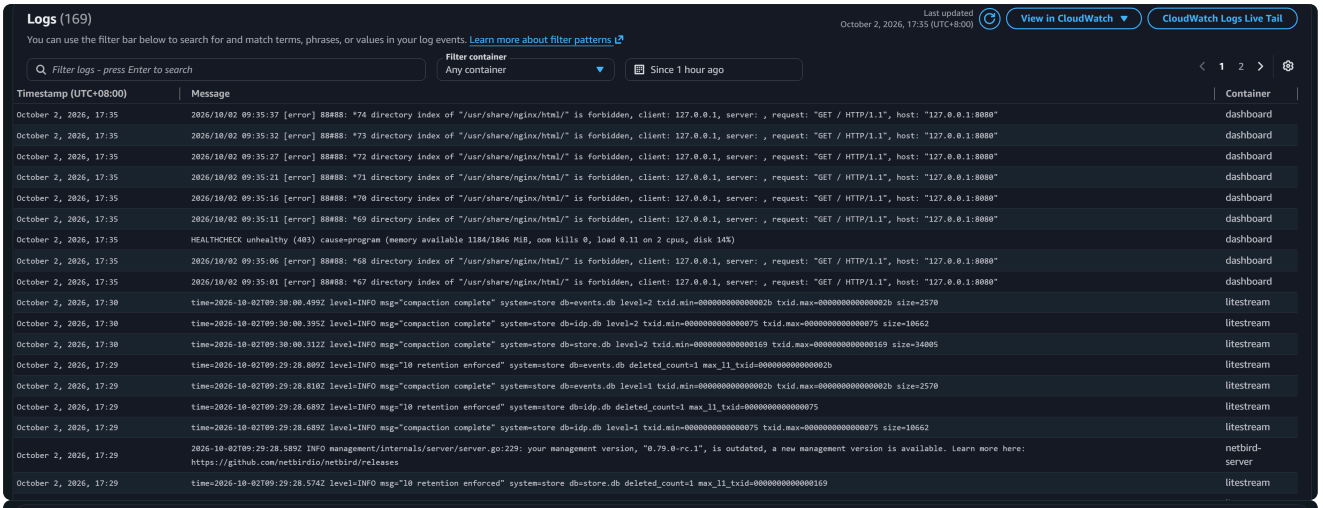
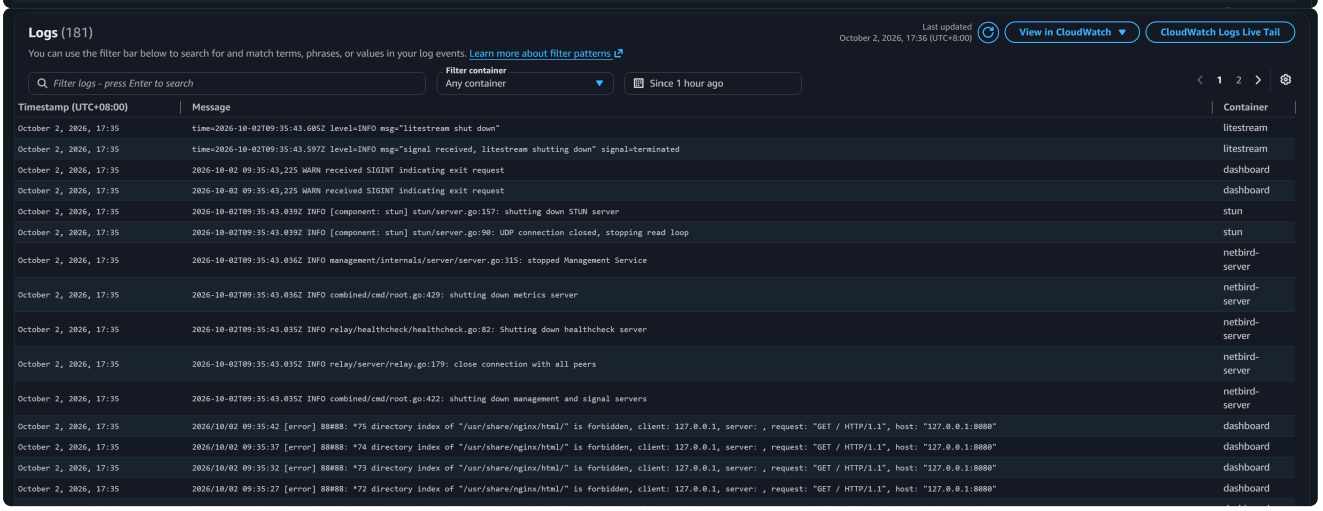




NetBird 實驗與健康檢查

實驗結果

實驗	做了什麼	結果
A	手動終止主機 4 次，看 spot 換機多久恢復	平均斷線 69 秒
意外	spot 真的被收走一次	斷線 491 秒，其中 4 分 16 秒是 ECS 空等
B	出價調到買不到 spot，看切到備援機再切回	切過去 18 分 22 秒，大部分在等告警。切回只斷 38 秒，但 EIP 被搬錯台，又斷 19 分鐘
A 延伸	新機器加入就叫 ECS 排 task	加入後 48 秒恢復
B 延伸	修正後再跑一次 B	全程自動，EIP 沒搬錯，但多重開一次，多斷 19 秒
A 延伸 2	還原改到 task 啟動，排 task 不建新部署	加入後 7 秒排上 task，43 秒恢復，沒有多重開
C	刪掉 dashboard 首頁，看健康檢查	第一次失敗後 43 秒 ECS 自動換 task
C 延伸	檢查改成每 5 秒、連續 2 次，加上原因紀錄	5 秒判定不健康，log 寫出原因是程式

發現的問題和改動

問題	改動
新機器加入後 ECS 不一定馬上排 task，重試間隔會越拉越長，最長 27 分鐘	主機開機腳本加入 cluster 後叫 ECS 馬上排，切到備援機時 Lambda 也這樣做
切回主機後 Lambda 處理了過期的事件，把 EIP 搬到正在關機的備援機	搬 EIP 前確認 task 真的在那台跑、那台是開著的
叫 ECS 排 task 用的是重新部署，會多重開一次	改成更新 service 但期望數量照舊，不建新部署
資料庫在開機時還原，切回主機時會蓋掉備援機上寫的資料	改成 task 啟動時才還原
stun 的健康檢查每次都多寫一行 log	stun 只記警告和錯誤
切到備援機要等 15 分鐘的告警	還沒改，下一步改成看事件

健康檢查

容器	檢查	頻率	變紅之後
netbird-server	openssl 打本機 443 的登入網址	每 5 秒，連續 2 次	重開整個 task
dashboard	curl 打容器內不記 log 的 8080	每 5 秒，連續 2 次	重開整個 task
stun	wget 打 relay 的 `/health`	每 5 秒，連續 2 次	只重開 stun
litestream	讀 metrics，看備份有沒有進度	每 10 秒，連續 3 次	只亮紅，保留現場

- 變紅時寫一行 `HEALTHCHECK unhealthy (...) cause=...`，cause 分 memory、cpu、disk、program。紅著每 5 分鐘提醒一次，恢復時寫 `recovered`
- 看原因：ECS console 進 task 的 Logs 分頁，選容器，搜尋 `HEALTHCHECK`。task 被換掉的話，要到 Stopped 的舊 task 看
- litestream 改成非必要容器，變紅不重開 task。重開會從 S3 還原，可能蓋掉還沒備份的資料
- litestream、stun 程式掛掉時只重開自己，但要先正常跑滿 5 分鐘，避免一直重開
- 檢查都在容器裡跑，不打 AWS API，成功時不寫 log，
- 判定不健康之後，ECS 還要 20 到 35 秒才換 task

跟 Lambda 怎麼配合

情況	事件	Lambda 怎麼做
買不到 spot	ASG 開機失敗	馬上切到備援機
新主機開好了	ASG 開機成功	穩定約 3 分鐘後切回
EIP 掛錯台	Route 53 檢查 EIP 的 80 埠	把 EIP 搬回跑 task 的那台

- 健康狀態改變不會發事件，只有 task 或容器停止才會。Lambda 收到停止事件後，再查停掉的 task 是哪個容器出問題
- 磁碟快滿不自動處理：30 GB 只用 14%，會寫進硬碟的東西都有上限或會自動清，正常不會滿。真的滿了多半是資料一直長，換新機器也會再滿。變紅時 `HEALTHCHECK` 的 `cause=disk` 看得出來
- 成本每月約 −$0.10 到 +$0.40，多一個 Route 53 檢查和告警，拿掉 `capacity-stable` 告警

實驗怎麼測

- 本機跑監控腳本，每秒打一次登入網址算斷線時間，每 5 秒記一次 EIP、ASG、task、備援機的狀態，ECS 跟 ASG 的事件紀錄也一起存
- 每個實驗先寫目的跟步驟，結論做完再補，資料放在 `5tmate/實驗/20261002/`，一次實驗一個資料夾
- 早上想過在 spot 收回預告的 2 分鐘內先開好另一台，但 ASG 上限要改成 2，要多一堆設定，也怕兩台同時跑，先不做

傍晚：切換改成看 ASG 事件（第 1 階段）

- 切到備援機不再等 15 分鐘的 `no-capacity` 告警，Lambda 收到 ASG 開機失敗的事件就切
- 新主機開好之後，收到開機成功的事件，等新主機加入 ECS、穩定 3 分鐘再切回
- 事件處理失敗只重試 1 次，超過 15 分鐘的事件直接丟掉，避免處理過期的事件

	實驗 B 延伸	實驗 B 延伸 2
切換的觸發	`no-capacity` 告警	ASG 開機失敗事件
主機被終止到開始切換	14 分 55 秒	1 分 9 秒
切到備援機的斷線	937 秒	133 秒
新主機開出到開始切回	6 分 28 秒	3 分 28 秒
切回的斷線	43 秒	47 秒

- `no-capacity` 告警全程沒響，EIP 最後在新主機上，備援機也關了
- 第一則開機失敗事件一定會被跳過。主機剛被終止時服務還有回應，Lambda 先不切，要等 ASG 大約 1 分鐘後的下一次重試，10/08 改成 ASG 沒機器就直接切

小結

開始用實驗量斷線時間，一般換機斷 69 秒。問題多半是等錯東西或順序不對，像 ECS 不會馬上排 task、EIP 搬錯台。傍晚改成看 ASG 事件，切到備援機從 937 秒降到 133 秒。

參考資料

- Amazon ECS service throttle logic - Amazon ECS(重試間隔最長 27 分鐘)
- UpdateService - Amazon ECS(`forceNewDeployment`)
- Determine Amazon ECS task health using container health checks - Amazon ECS
- Restart individual containers in Amazon ECS tasks with container restart policies - Amazon ECS(stun、litestream 只重開自己)
- Amazon ECS task state change events - Amazon ECS
- Amazon EC2 Auto Scaling events - Amazon EventBridge(開機成功、開機失敗)
- Configuring error handling settings for Lambda asynchronous invocations - AWS Lambda(重試次數、事件最長保留時間)
- Creating Amazon Route 53 health checks - Amazon Route 53
- Command: restore - Litestream
- Spot Instance interruption notices - Amazon EC2(2 分鐘警告)